

DATA COMMUNITY GDAŃSK #32 · 18 MARCA 2026

Fabric IQ: czyli o co chodzi z tą ontologią w praktyce



Ready.

Twój AI jest inteligentny. Ale czy rozumie Twój biznes?

#Microsoft

#FabricIQ

#Ontology

#NieChodziOXML

△ Public Preview — marzec 2026

Speaker Information



Dr. Estera Kot

CTO, Clouds on Mars

Microsoft Fabric Featured Partner · PhD AI

← → Nawigacja klawiaturą | F11 Pełny ekran

Dr. Estera Kot — Chief Technology Officer

Speaker Profile



Dr. Estera Kot

Chief Technology Officer

Clouds on Mars

Data & AI Engineer

Cloud Architect

Microsoft Fabric Specialist

LinkedIn

@esterakot

Professional Profile

Organization	Clouds on Mars
Role	Chief Technology Officer
Background	Principal PM · Microsoft Azure Synapse & Fabric
Education	PhD · Computer Science
Engineering	Apache Spark · Azure · Big Data at scale
Partner Status	✓ Microsoft Fabric Featured Partner

BACKGROUND

MSFT Veteran

electrical & software engineering

ACADEMIC

PhD Technology

ENGINEERING

Spark Expert

STRATEGY

AI & Data

Ontologia: 2500 lat przed Power BI

Word Properties — ontologia.exe

ὄντος

ontos

być · istnienie

"that which exists"

+

λόγος

logos

słowo · nauka

"word / study of"

=

ONTOLOGIA

nauka o bycie

"study of what exists and how things relate"

~450 p.n.e. — Filozofia

Aristoteles

Metafizyka — "nauka o bycie jako bycie"

1993 — Computer Science

Tom Gruber (Stanford)

"An ontology is a specification of a conceptualization."

2025 — Microsoft Fabric IQ

Business Ontology

AI rozumie **znaczenie**, nie tylko nazwy kolumn.

i

Kluczowa myśl: Aristoteles pytał: "Co istnieje i jak się relacjonuje?" Fabric IQ odpowiada: modelujemy to razem — i dajemy temu engine obliczeniowy.

Ten sam model AI. Zupełnie inne odpowiedzi. Dlaczego?

❌ AI BEZ ONTOLOGII

Analitik pyta: "Pokaż zamówienia z ryzykiem SLA"

"Co oznacza sla_flag? Nie rozumiem kontekstu."

- ▶ Rozumie kolumny, nie biznes
- ▶ Endless prompt engineering
- ▶ Różne definicje "klienta" per report
- ▶ Nieauditowalne odpowiedzi

FABRIC IQ



ontologia

✅ AI Z ONTOLOGIĄ

Analitik pyta: "Pokaż zamówienia z ryzykiem SLA"

 AI: "Znalazłem **847 zamówień** z ryzykiem SLA. Łączna wartość: **2,1M PLN**. Najczęstsza przyczyna: opóźnienie u dostawcy cold-chain."

- ▶ Rozumie znaczenie biznesowe
- ▶ Zero prompt engineeringu
- ▶ Unified semantic model
- ▶ Audytowalne, trackowalne decyzje

* Liczby ilustracyjne — przykład typowego wdrożenia

Kluczowa myśl: Ontologia to nie schemat bazy danych — to zakodowana logika biznesowa, którą AI rozumie.

Pięć capabilities. Jeden semantic brain.

 **ONTOLOGY (preview)**
encje · relacje · reguły · właściwości

 **Semantic Models**
Power BI + Lakehouse · 20M+ models

 **Graph (preview)**
GQL traversal · multi-hop chains

 **Data Agent (preview)**
NL → GQL/KQL/SQL · Q&A · pyta

 **Operations Agent (preview)**
Observe → Analyze → Decide → **Act**

Kluczowa różnica: Data Agents *odpytują*. Operations Agents *wykonują decyzje*. Oba gruntowane na tej samej ontologii.

Ontologia = AI które nie zgaduje.

5 komponentów, które zamieniają dane w zrozumienie

1. Entity Types — "rzeczowniki" biznesu

Customer · Order · Shipment · Supplier

Nie tabele w bazie — abstrakcyjne typy z semantycznym znaczeniem.
AI wie **czym jest** "Customer", nie tylko że to wiersz w dbo.customers.

2. Relationship Types — "czasowniki" łączące encje

Customer —[PLACED]→ Order —[SHIPPED_VIA]→ Shipment

AI rozumie **kontekst** — wie, że zamówienie należy do klienta.
Nie musi tego wywnioskować z JOIN-ów.

3. Properties — atrybuty z opisem biznesowym

Nie chodzi o VARCHAR(255) — chodzi o intencję biznesową:

delivery_date → "committed delivery date per SLA agreement"
risk_score → "composite risk metric, 0-100, threshold ≥ 70 = escalation"

4. Rules ← tu jest magia

Logika żyje w modelu, nie w prompcie:

```
IF delivery_date > SLA_threshold → risk = SLA_BREACH
IF order_value > 100k AND segment = "Enterprise"
  → priority = CRITICAL
```

Wersjonowane · testowalne · audytowalne.
Zmiana SLA? **Jedno miejsce**, nie 15 promptów.

5. Agent Actions — co AI może zrobić


Teams → alert do account managera
Power Automate → flow eskalacji
ERP → aktualizacja statusu zamówienia

Ontologia definiuje nie tylko "co wiem", ale też "co mogę z tym zrobić".

Bez ontologii: prompt = kontekst + reguły + definicje. Kruchy, niepowtarzalny, nietestowalny.
Z ontologią: prompt mówi "sprawdź ryzyko" — agent **sam wie** co to znaczy.

Jeden sensor. Trzy hopy dalej — SLA breach.

Graph Engine traversuje łańcuch: anomalia sensora → naruszenie SLA — w jednym zapytaniu



❗ Cold Chain — co to jest?

Łańcuch chłodniczy — transport produktów wymagających kontrolowanej temperatury: leki, żywność, szczepionki. Cold Chain Event = moment naruszenia warunków (np. czujnik w ciężarówce rejestruje odchylenie >4°C). Dzięki ontologii jedno zdarzenie z sensora IoT automatycznie eskaluje do ryzyka biznesowego — bez ręcznego łączenia danych z 4 systemów.

Zapytanie GQL (Graph Query Language)

```
MATCH (s:Sensor)-[:TRIGGERS]->
      (e:ColdChainEvent)-[:AFFECTS]->
      (sh:Shipment)-[:PART_OF]->
      (o:Order)-[:ORDERED_BY]->
      (c:Customer)
WHERE e.temp_deviation > 4.0
      AND o.sla_deadline < NOW() + 48h
RETURN o.order_id, c.name,
       o.value_pln, sh.eta
```

Wynik w sekundach

Znalezione: 12 zamówień zagrożonych

Łączna wartość: 847 tys. PLN

Klienci premium: 3 (eskalacja auto)

Czas zapytania: < 2s

Bez ontologii: 4 zapytania SQL, 3 JOIN-y, ręczna korelacja danych z 2 systemów. Czas: 2–4 godziny.

Jeden pyta. Drugi działa.

 Data Agents

Conversational Intelligence

✓ Natural Language → GQL/KQL/SQL routing

✓ Ad-hoc analytics na żywo

✓ KPI monitoring i alerty

✓ Q&A z kontekstem biznesowym

"Ile zamówień przekroczyło SLA w tym tygodniu, i którzy klienci są dotknięci?"

→ Odpowiedź semantyczna, nie tylko SQL

 Operations Agents

Autonomous Decision-Making

✓ Observe → Analyze → Decide → Act

✓ Optymalizacja tras, stanów, zasobów

✓ Prewencja SLA (przed naruszeniem)


✓ Teams approval → Power Automate → ERP

Sensor wykrywa odchylenie → Agent analizuje → Teams: "Approve re-routing?" → Power Automate → system logistyczny


→ Działanie autonomiczne, człowiek w pętli

Data Agent — informuje · **Operations Agent** — decyduje (human-in-the-loop)

OneLake trzyma. Fabric przetwarza. IQ rozumie.



340 naruszeń SLA miesięcznie. Zostaje 45.



Zanim zaczniesz — 6 ustawień w Admin Portal

L100

Tenant Settings — wymagane (✓)

- ✓ Enable Ontology item type
- ✓ Users can create Graph (!) — **krytyczne**
- ✓ Data agent item types
- ✓ Enable Copilot + OpenAI workloads

Opcjonalne (•)

- ▶ Cross-geo data sharing
- ▶ Cross-geo data storing

⚠ Error — Unable to create Ontology OK

🚫 **Gotcha #1:** Ontology ON, ale Graph OFF → nie działa.
Oba muszą być włączone.

OK

⚠ Warning — F-SKU Required OK


⚠ **Gotcha #2:** Trial SKU → nie działa.
Minimum **F64** wymagane.

OK

Pro tip: Dedykowany workspace dla Fabric IQ — oddzielnie od produkcji.

Buduj ontologię: 5 kroków

L200



NAMING RULES: bez spacji/myślników · PRODUCT zarezerwowane → użyj Product_item

DATA REFRESH:

- Lakehouse binding → manual refresh wymagany
- Eventhouse binding → live/real-time, bez refresh

```
-- Po wygenerowaniu ontologii – weryfikacja w Graph Explorer
SELECT * FROM ONTOLOGY.entities WHERE type = 'Customer'
-- Lub w GQL:
MATCH (c:Customer) RETURN c LIMIT 10
```

Query routing: NL → GQL / KQL

L300



GQL — Graph Query Language

Dla relacyjnych zapytań traversalnych

```
MATCH (s:Supplier)
-[:DELIVERS]->(p:Product_item)
-[:PART_OF]->(o:Order)
WHERE s.on_time_rate < 0.85
AND o.value_pln > 50000
AND o.quarter = 'Q1'
RETURN s.name,
       count(o) as delays,
       sum(o.value_pln) as risk_pln
ORDER BY risk_pln DESC
```

KQL — Eventhouse Time-Series

Dla real-time i time-series analityki

```
SensorReadings
| where machine_id in (
  toscalar(
    ColdChainAssets
    | where asset_type == 'refrigerated_truck'
    | summarize make_list(machine_id)
  )
)
| where timestamp > ago(4h)
| summarize avg_temp = avg(temperature),
             max_deviation = max(temp_deviation)
by machine_id, bin(timestamp, 15m)
```

Known issue: GROUP BY w GQL może generować błędy na niektórych binding typach. Używaj RETURN ... count().

GQL — pierwszy język grafów od czasu SQL

ISO/IEC 39075 (kwiecień 2024) — pierwszy nowy standard języka zapytań od SQL (1987)

2007 — Neo4j & Cypher

Pierwszy język grafowy
ASCII-art składnia: (a)–[:KNOWS]–>(b)
De facto standard, ale własność Neo4j.

2019 — Prace ISO

Neo4j + Oracle + Google + Microsoft + IBM
Trzy źródła: **Cypher** (Neo4j), **PGQL** (Oracle), **G-CORE** (akademia).

2024 — GQL = ISO Standard

ISO/IEC 39075
Vendor-agnostic. Tak jak SQL ustandaryzował tabele, **GQL standaryzuje grafy**.

SQL — myśli w tabelach

```
SELECT o.order_id, c.name
FROM sensors s
JOIN events e ON s.id = e.sensor_id
JOIN shipments sh ON e.shipment_id = sh.id
JOIN orders o ON sh.order_id = o.id
JOIN customers c ON o.customer_id = c.id
WHERE e.temp_deviation > 4.0
```

5 tabel · 4 JOIN-y · musisz znać klucze obce

GQL — myśli w relacjach

```
MATCH (s:Sensor)-[:TRIGGERS]->
      (e:ColdChainEvent)-[:AFFECTS]->
      (sh:Shipment)-[:PART_OF]->
      (o:Order)-[:ORDERED_BY]->
      (c:Customer)
WHERE e.temp_deviation > 4.0
RETURN o.order_id, c.name
```

Czytasz jak zdanie. Wzorzec relacji wprost w zapytaniu.

PATTERN MATCHING

opisujesz wzorzec → silnik go znajduje

MULTI-HOP NATYWNIIE

4 hopy = 1 wyrażenie, nie 4 JOIN-y

ISO STANDARD

vendor-agnostic — MSFT, Oracle, Neo4j

W Fabric IQ: Agent AI nie pisze SQL-a z 5 JOIN-ami — formułuje GQL, który naturalnie opisuje ścieżkę po relacjach biznesowych. Ontologia definiuje węzły i krawędzie, GQL po nich przechodzi.

Operations Agent: Observe → Analyze → Decide → Act

L400

5-krokowa konfiguracja

- 1

Business Goals (natural language)
- 2

Agent Instructions — limity uprawnień
- 3

Knowledge Source — KQL trigger
- 4

Actions — Power Automate: Teams · ERP · SCADA
- 5

Save → Playbook → Start agent



TEAMS INTEGRATION
Teams → Yes/No → Power Automate → pełna auditability



SECURITY MODEL
Delegated identity · Write permission · konto serwisowe



FULL LOOP
Activator → KQL → Teams → Power Automate → ERP/SCADA

Wszyscy mają RAG. Nikt nie ma ontologii. Jeszcze.

Traditional BI — odpowiada RAG — generuje **Fabric IQ — rozumie ✓**

Capability	Traditional BI (Power BI, Tableau)	RAG-based AI (Databricks, Snowflake AI)	★ Fabric IQ
Business Ontology	—	✗	✓ Native
Real-time Graph Traversal	✗	— (limited)	✓ GQL
Autonomous Actions (Agents)	✗	— (preview)	✓ Preview
Multi-source Binding	— (connectors only)	— (manual)	✓ OneLake native
AI Agent Grounding	✗	— (vector only)	✓ Semantic+Vector

"The next frontier is not who has the most data or the best model — it's shared understanding between humans and AI at scale."

Masz Power BI? Masz już 80% ontologii.

Prerequisites → Activate → Extend



Start with what you have: PBI Semantic Model + relacje + DAX = gotowa ontologia. Fabric IQ generuje automatycznie.



8 tygodni. Pierwszy agent z kontekstem biznesowym.

4 sprinty · od discovery do mierzalnego ROI

- SPRINT 1 · W1–W2
Discovery
2–3 use cases · mapa encji
- SPRINT 2 · W3–W4
Ontology Build
Ontologia z PBI · binding · Graph testy
- SPRINT 3 · W5–W6
Agent Deployment
Data Agent + Ops Agent · Teams workflow
- SPRINT 4 · W7–W8
Measure & Scale
KPI vs baseline · business case

Target metrics po 8 tygodniach



Clouds on Mars prowadzi POC. Discovery możliwy w ciągu 2 tygodni.

Twój AI myśli po angielsku. Twój biznes mówi po polsku.

✖ BEZ ONTOLOGII

- ▶ AI rozumie kolumny, nie biznes
- ▶ Różne definicje "klienta" per raport
- ▶ Endless prompt engineering
- ▶ Nieauditowalne odpowiedzi
- ▶ Data Mesh chaos — każdy team robi swoje
- ▶ AI pisze SQL, ale nie wie *dla*czego

czas analityków · błędy decyzyjne · brak skali

FABRIC IQ



ontologia

✔ Z ONTOLOGIĄ

- ▶ AI rozumie znaczenie biznesowe
- ▶ Unified semantic model dla org
- ▶ Zero prompt engineering (standard)
- ▶ Auditowalne, śledzalne decyzje
- ▶ 80% reuse z istniejącego PBI
- ▶ Agenty działają, nie tylko odpowiadają

szybsza reakcja · mniej SLA · lepsze decyzje

Masz PBI Semantic Model? Masz fundament. Jeden krok.

Dołącz do nas — We Are Hiring!

CTO Office @ Clouds on Mars

- | | |
|---|---|
| ✓ Senior Data Engineer | ✓ Consulting Lead – Pharma, Lifesciences & Healthcare |
| ✓ Senior BI Consultant | |
| ✓ Project Manager | ✓ Business Analyst |
| ✓ BI Consultant | ✓ AI Engineer |
| ✓ Consulting Lead – Services, Retail & Consumer | ✓ Team Lead – Data Engineer |
| | ✓ Power Platform Consultant |

Dlaczego Clouds on Mars?

- ✓ **Microsoft Featured Partner** — pracujesz z edge produktami
- ✓ **CTO-led** — bezpośredni dostęp do decision makerów
- ✓ **Real projects** — nie PoC, a produkcja u klientów Enterprise
- ✓ **Praca zdalna** — EU, min. kwartalnie spotkania zespołowe w Polsce
- ✓ **Biuro:** Warszawa, Metro Wilanowska

✉ estera.kot@cloudsonmars.com
cloudsonmars.com · LinkedIn: Clouds on Mars

Clouds on Mars

Let your data
make an impact

▶ Watch on YouTube

🌐 Aplikuj przez stronę:
cloudsonmars.com/careers/

Q&A Challenge

Trzy pytania. Trzy gadżety. Najlepsze odpowiedzi wygrywają.

Pytanie #1

Wymien jeden scenariusz w swojej organizacji, gdzie multi-hop reasoning Fabric IQ rozwiązałby problem, którego Power BI sam nie ogarnie.

Hint: pomyśl o łańcuchu zależności między tabelami, którego JOIN nie pokryje.

Pytanie #2

Gdybys miał/a wdrożyć ontologię w swoim lakehouse — od jakiej domeny biznesowej byś zaczął/a i dlaczego?

Hint: ontologia to nie tabela — to model relacji biznesowych.

Pytanie #3

Jaka widzisz największą barierę adopcji Fabric IQ w polskich firmach — techniczna, organizacyjna czy kulturowa?

Hint: nie ma złej odpowiedzi — uzasadnij swój wybór.

 **Zasady:** Odpowiadasz na głos, przy mikrofonie. Najciekawsza odpowiedź na każde pytanie = gadżet od Clouds on Mars.

Pytania? Dziękuję!

One step from Power BI to AI that truly understands your business.

Microsoft Fabric Featured Partner

Advanced Specialization Analytics

AI-native · 8 PhD



Dr. Estera Kot

CTO, Clouds on Mars

✉ estera.kot@cloudsonmars.com

🌐 cloudsonmars.com



Ankieta / Feedback

Zeskanuj QR code

Twoja opinia jest wazna!

Naciśnij ESC aby wrócić do menu · ← → nawigacja slajdami

```
C:\WINDOWS\system32> shutdown /s /t
300 /c "Thank you for attending!"
System shutting down in 5:00
minutes...
```

Semantic Model vs Ontologia — po co ta dodatkowa warstwa?

Semantic Model (Power BI / Tabular)

```
dim_Customer[customer_id]
  → fact_Orders[customer_id]
// relacja 1:N, cross-filter: Both
// Power BI wie jak filtrować.
// Nie wie co to znaczy biznesowo.
```

- ▶ Tabele, kolumny, miary DAX, relacje FK→PK
- ▶ Relacje **techniczne** — JOIN-y między tabelami
- ▶ Odpowiada na **"ile?"**
- ▶ Konsument: **człowiek** (dashboard)

Ontologia (Fabric IQ)

```
Customer -[PLACED]-> Order
customer.segment = "Enterprise"
order.sla_hours = 48
Rule: IF delivery > sla → SLA_BREACH
Action: ON BREACH → Teams + PA
```

- ▶ Encje biznesowe, reguły, akcje agenta
- ▶ Relacje **semantyczne** — biznesowy kontekst
- ▶ Odpowiada na **"co to znaczy i co z tym zrobić?"**
- ▶ Konsument: **agent AI** (autonomiczne działanie)

	Semantic Model	Ontologia
Pytanie	"Ile zamówień w Q1?"	"Które zamówienia zagrażają SLA klienta Enterprise?"
Odpowiedź	Liczba (KPI, raport)	Insight + akcja (alert, eskalacja)
Relacje	FK/PK (techniczne)	Semantyczne (Customer PLACED Order)
Reguły	DAX measures (obliczenia)	Business rules (logika decyzyjna)
Traversal	Nie — filtrowanie w modelu	Tak — multi-hop across entities (GQL)

Punchline: Semantic Model to **punkt startu**, nie konkurencja. Fabric IQ czyta Twoje tabele, relacje i miary, i **dodaje warstwę semantyczną** — opisy biznesowe, reguły, akcje. Nie zastępuje modelu — **wzbogaca go** o kontekst, którego AI potrzebuje żeby nie tylko raportować, ale działać.