
Data
Community
Trójmiasto
Wyszukiwanie wektorowe – po mojemu albo po niczemu!
Od prototypu do produkcji z Percona for MongoDB
PERCONA

Wyszukiwanie wektorowe – po mojemu albo po niczemu!

Od prototypu do produkcji z Percona for MongoDB



Radoslaw Szulgo,
Senior Product Manager,
Percona

PERCONA



PERCONA®

OGROMNA RÓŻNICA

Tym co chcemy
vs
Tym co otrzymujemy

PERCONA®

Ogromna różnica...



Pułapka Wygody



PERCONA

Od słów kluczowych do znaczenia

SQL: `LIKE`

01

Predykat zapytania

$text

Standardowy operator zapytania do dopasowywania tekstu, wbudowany bezpośrednio w MongoDB.

SQL: `CONTAINS` / `FREETEXT`

02

Wyszukiwanie pełnotekstowe

$search

Rozbudowane funkcje wyszukiwania, wykorzystujące MongoDB z Lucene we frameworku agregacji (aggregation framework). Obejmują dopasowywanie przybliżone (fuzzy matching), autouzupełnianie oraz analizatory językowe.

SQL: `VECTOR_DISTANCE`

03

Vector Search

$vectorSearch

Wyszukiwanie semantyczne oraz wyszukiwanie według podobieństwa, oparte na modelu językowym (LLM) i umożliwiające integrację wektorów wysoko wymiarowych bezpośrednio wewnątrz bazy danych.

PERCONA

Biznesowe znaczenie wyszukiwania

"Brak wyników"

Wyszukiwanie według dokładnych słów kluczowych zawodzi, gdy użytkownik szuka rozwiązania, a nie dokładnej nazwy produktu.

Globalizacja

Przy wyszukiwaniu wektorowym można pominąć kosztowne etapy tłumaczenia. Baza danych rozumie znaczenie niezależnie od języka. Np. bezpośrednio dopasowując zapytania w języku polskim do katalogów anglojęzycznych.

Precyzyjna generatywna sztuczna inteligencja (RAG)

Nowoczesne modele językowe (LLM) wymagają precyzyjnego, uwzględniającego kontekst wyszukiwania dokumentów w bazie danych, aby generować dokładne odpowiedzi bez halucynacji.

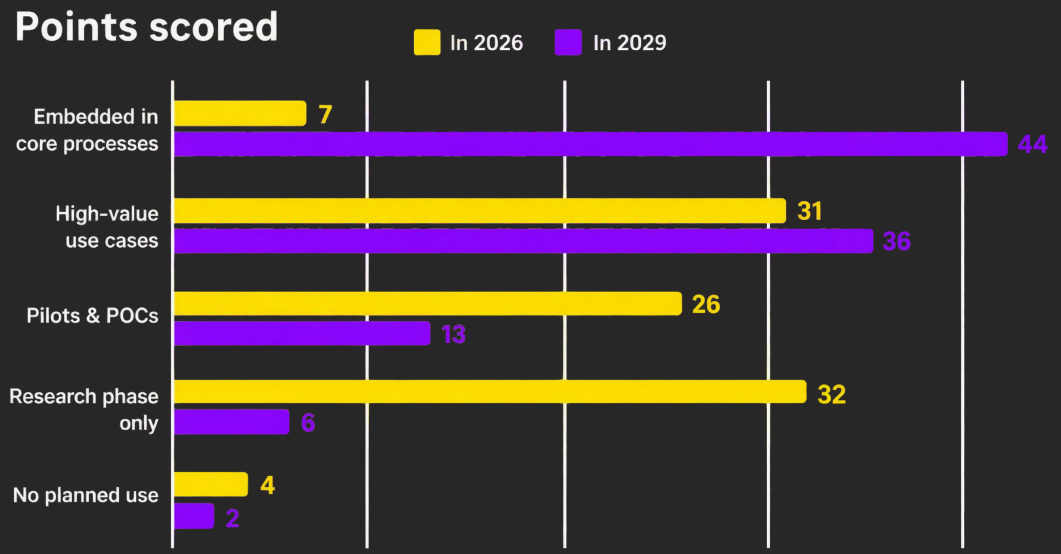
Zainteresowanie AI jest wysokie ale adopcja jest Niska... Na razie!

Dziś: Wczesny etap

7% używane w krytycznych procesach
31% używane w ważnych przypadkach
26% używane testowo (POC i piloty)
32% w badaniach lub brak planów

Za 3 lata

44% będzie w krytycznych procesach
36% będzie w ważnych przypadkach
13% uważa, że wciąż będzie testować
6% uważa, że wciąż będzie w badaniach lub nie ma planów



Source: Accelerating AI Use Cases in 2026 by HiveMQ | The Industrial Data, Intelligence & AI Readiness Survey Report | Insights from 272 professionals

Tłumaczenie znaczenia przez matematykę

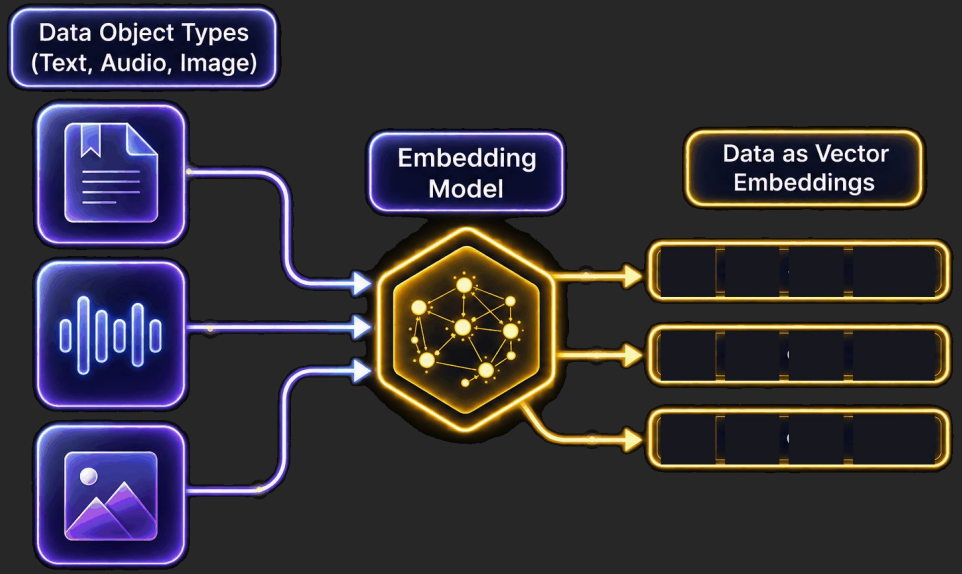
Zadanie

Problem: Baza danych nie potrafi odczytać znaczenia czy intencji

Rozwiązanie: Przekształcenie języka do matematycznej reprezentacji danych

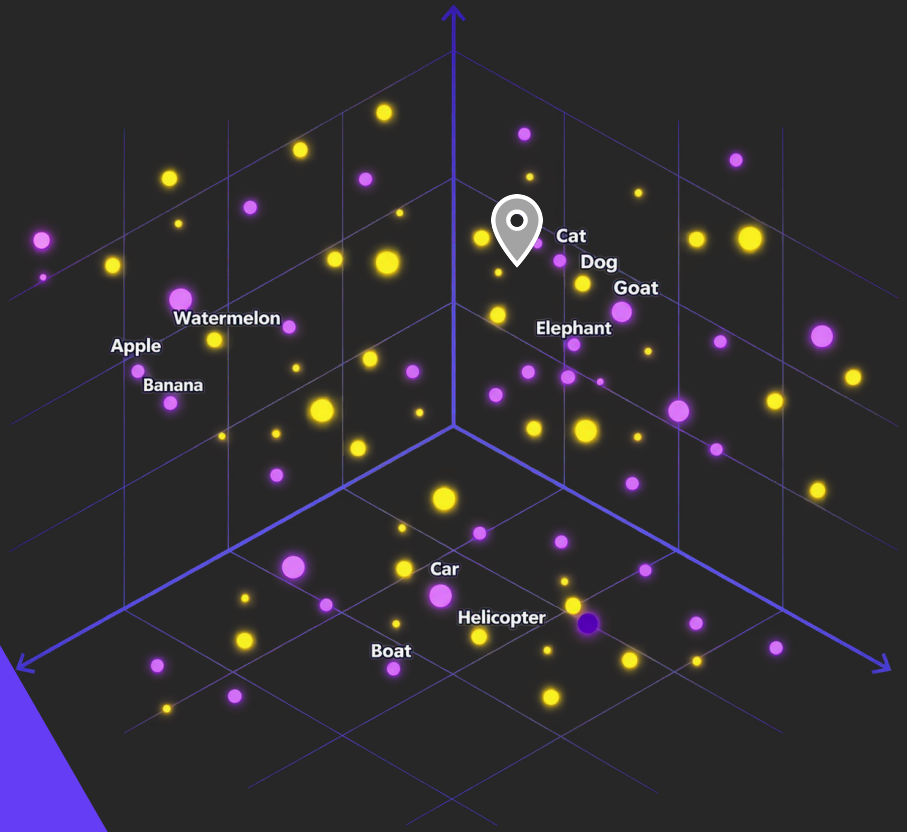
Kluczowe pojęcie

Embedding: Wektor, który odwzorowuje dane (tekst, dźwięk, lub obraz) w ciągłą przestrzeń wektorową.



PERCONA

Wymaganie: Odwzorowanie danych



Mapa wielowymiarowa

Wektory pełnią funkcję współrzędnych na wielowymiarowej mapie

Generowanie wektorów

Za każdym razem, gdy dane są dodawane lub aktualizowane, muszą zostać przekształcone w wektor i zapisane wraz z tymi danymi.

Grupowanie semantyczne

Pojęcia o zbliżonych kontekstach w naturalny sposób grupują się w tej wielowymiarowej przestrzeni.

PERCONA

Geometria

01

Utworzenie współrzędnych

Model AI przekształca tekstowy prompt w nową współrzędną w przestrzeni wektorowej.

02

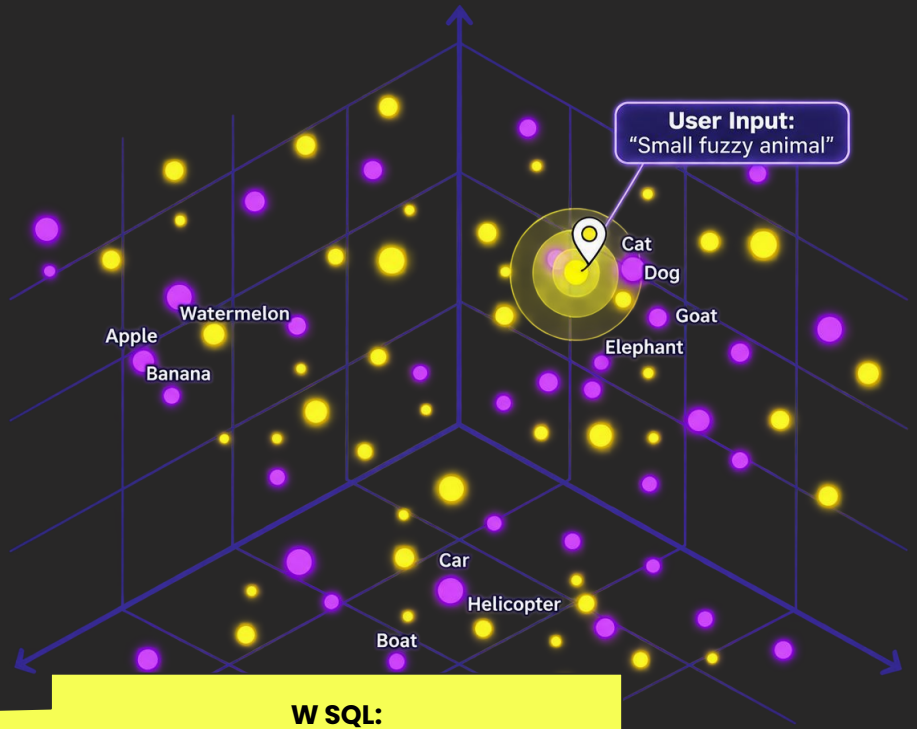
Odwzorowanie w przestrzeni

MongoDB przyjmuje tę współrzędną i nanosi ją bezpośrednio na mapę, obok zgrupowanych danych.

03

Obliczanie dystansu

Baza danych błyskawicznie oblicza najkrótszą odległość, aby znaleźć najbliższych sąsiadów (ANN/HNSW).



W SQL:
APPROX_COUNT_DISTINCT
zwraca szacunkową liczbę unikalnych wartości niebędących wartościami `null` w kolumnie lub wyrażeniu

PERCONA®

© 2026 Percona

Opcje Generowania Wektorów

Ręczny

Po stronie aplikacji (DB klienta)

✓ **Zalety**

Pełna swoboda wyboru dowolnego modelu AI oraz bezpośrednia kontrola nad kosztami API

✗ **Wady**

Wysokie wymagania konserwacyjne: wymaga niestandardowych potoków, synchronizacji danych i zarządzania spójnością transakcji. Czyli - własny ETL.

Automatyczny

Zintegrowany w bazie danych

✓ **Zalety**

Zintegrowany proces obsługujący generowanie i aktualizacje w sposób automatyczny w momencie dodania dokumentu

✗ **Wady**

W oryginalnym rozwiązaniu MongoDB automatyzacja ta jest obecnie ograniczona wyłącznie do modeli Voyage AI.

PERCONA®

© 2026 Percona

Dylemat Wyszukiwania w MongoDB

Pułapka

MongoDB Community umożliwia szybką, automatyczną konfigurację, lecz w znacznym stopniu ogranicza swobodę architektoniczną.

Wymuszona integracja

Zyskujesz bezproblemowe generowanie danych, ale jednocześnie zostajesz „zamknięty” w systemie, który wymaga przesyłania ważnych informacji wyłącznie za pośrednictwem Voyage AI.

Utrata kontroli

Programiści rezygnują ze swobody wyboru własnych modeli oraz kontroli nad kosztami infrastruktury.

PERCONA®

© 2026 Percona

Rebelianci o wolność

PERCONA®



Chcemy wygody i
domagamy się wolności,
jaką daje otwarte oprogramowanie

PERCONA®

Realny koszt wymuszonych integracji: Dlaczego warto walczyć?

Elastyczność modeli

Sztuczna inteligencja rozwija się z tygodnia na tydzień; związanie się z jednym dostawcą uniemożliwia przejście na alternatywne rozwiązania, które mogą okazać się o 50% tańsze lub dwukrotnie szybsze.

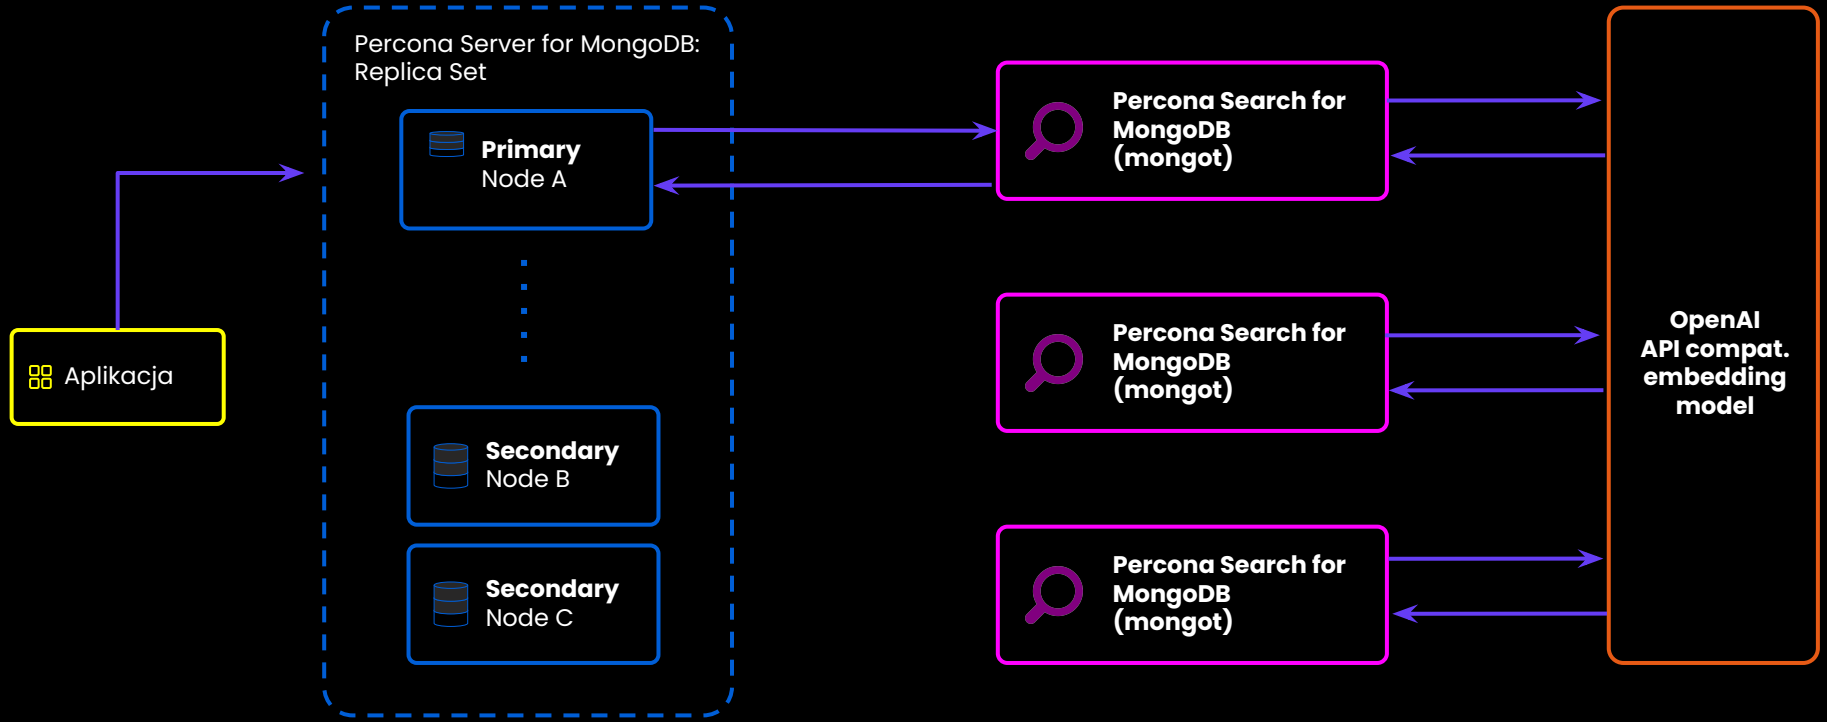
Zgodność z przepisami i suwerenność danych

Przepisy (RODO, HIPAA, ochrona własności intelektualnej przedsiębiorstw) często uniemożliwiają przesyłanie wrażliwych danych operacyjnych za pośrednictwem zewnętrznych, własnościowych interfejsów API dostarczanych przez podmioty trzecie.

PERCONA®

© 2026 Percona

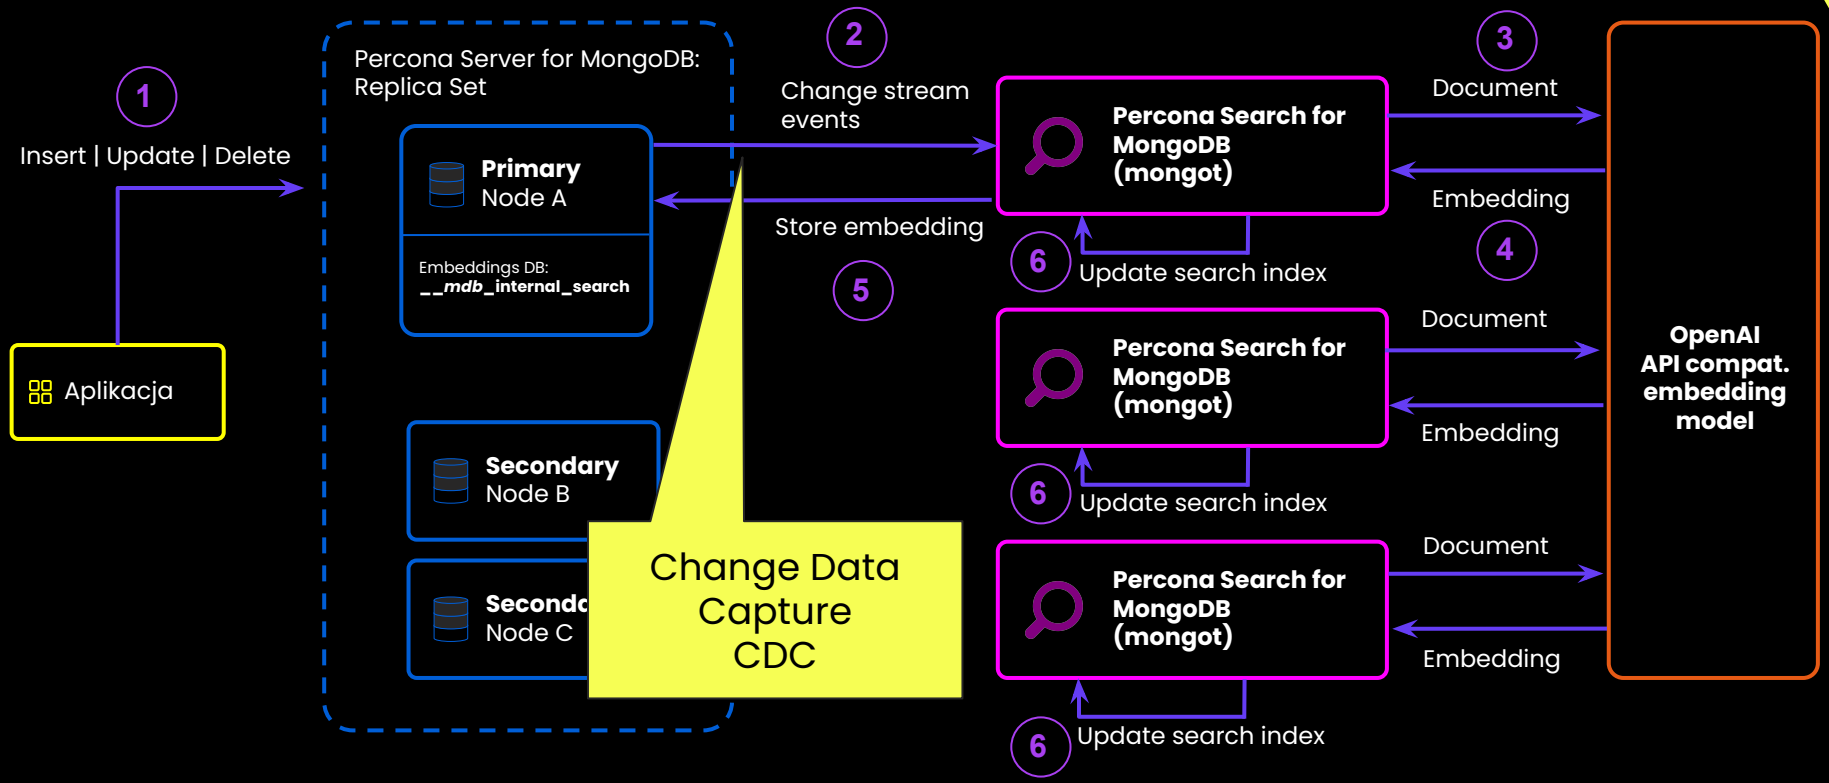
Percona Search for MongoDB architektura



Percona Server for MongoDB 8.3+
Percona Search for MongoDB 1.70.4+

PERCONA

Percona Search for MongoDB architektura

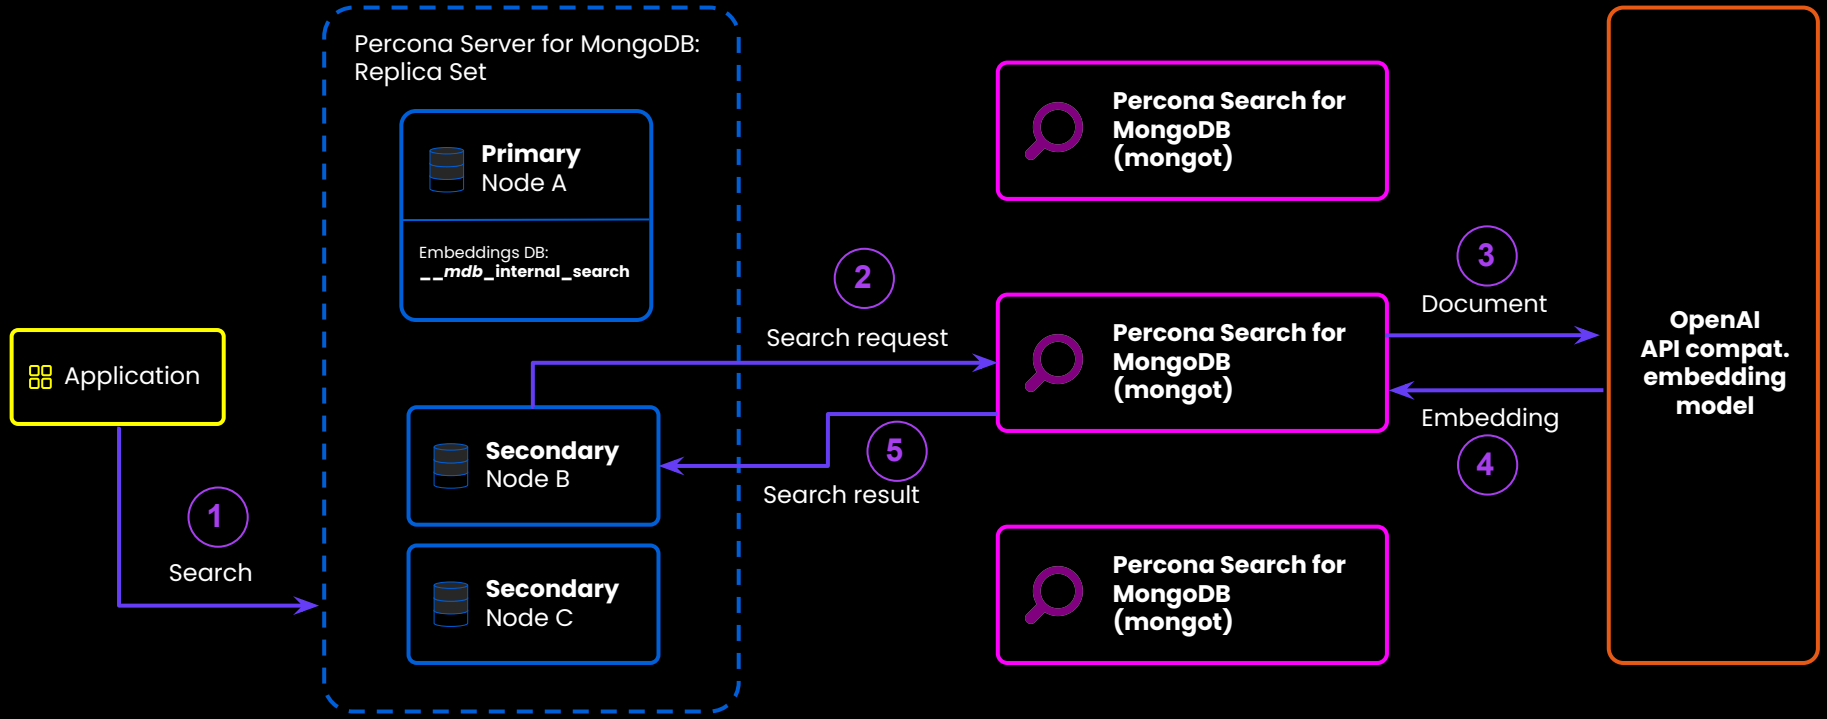


Percona Server for MongoDB 8.3+

Percona Search for MongoDB 1.70.4+

PERCONA

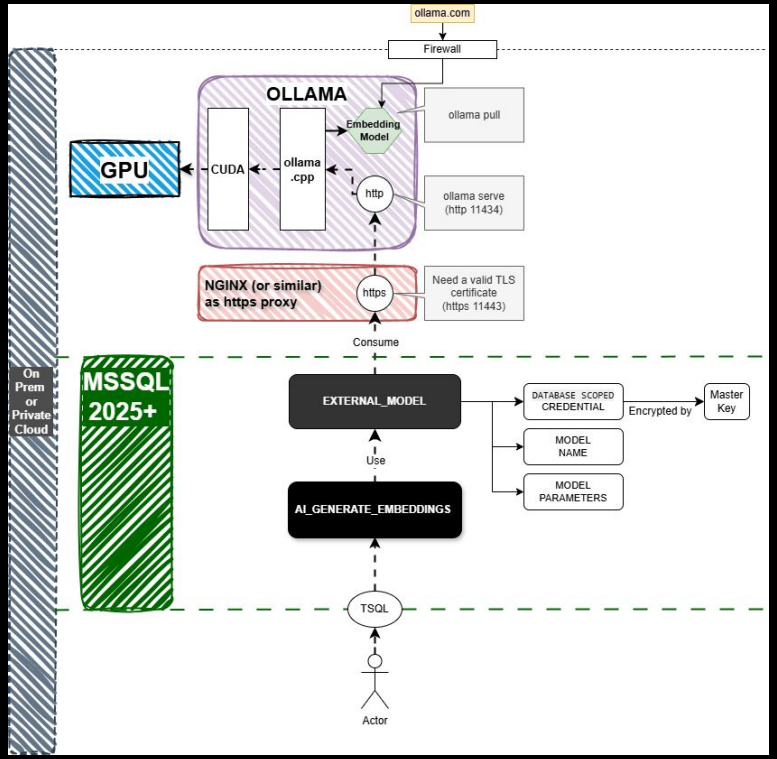
Percona Search for MongoDB architecture



Percona Server for MongoDB 8.3+
Percona Search for MongoDB 1.70.4+

PERCONA

Microsoft SQL Server 2025+



PERCONA

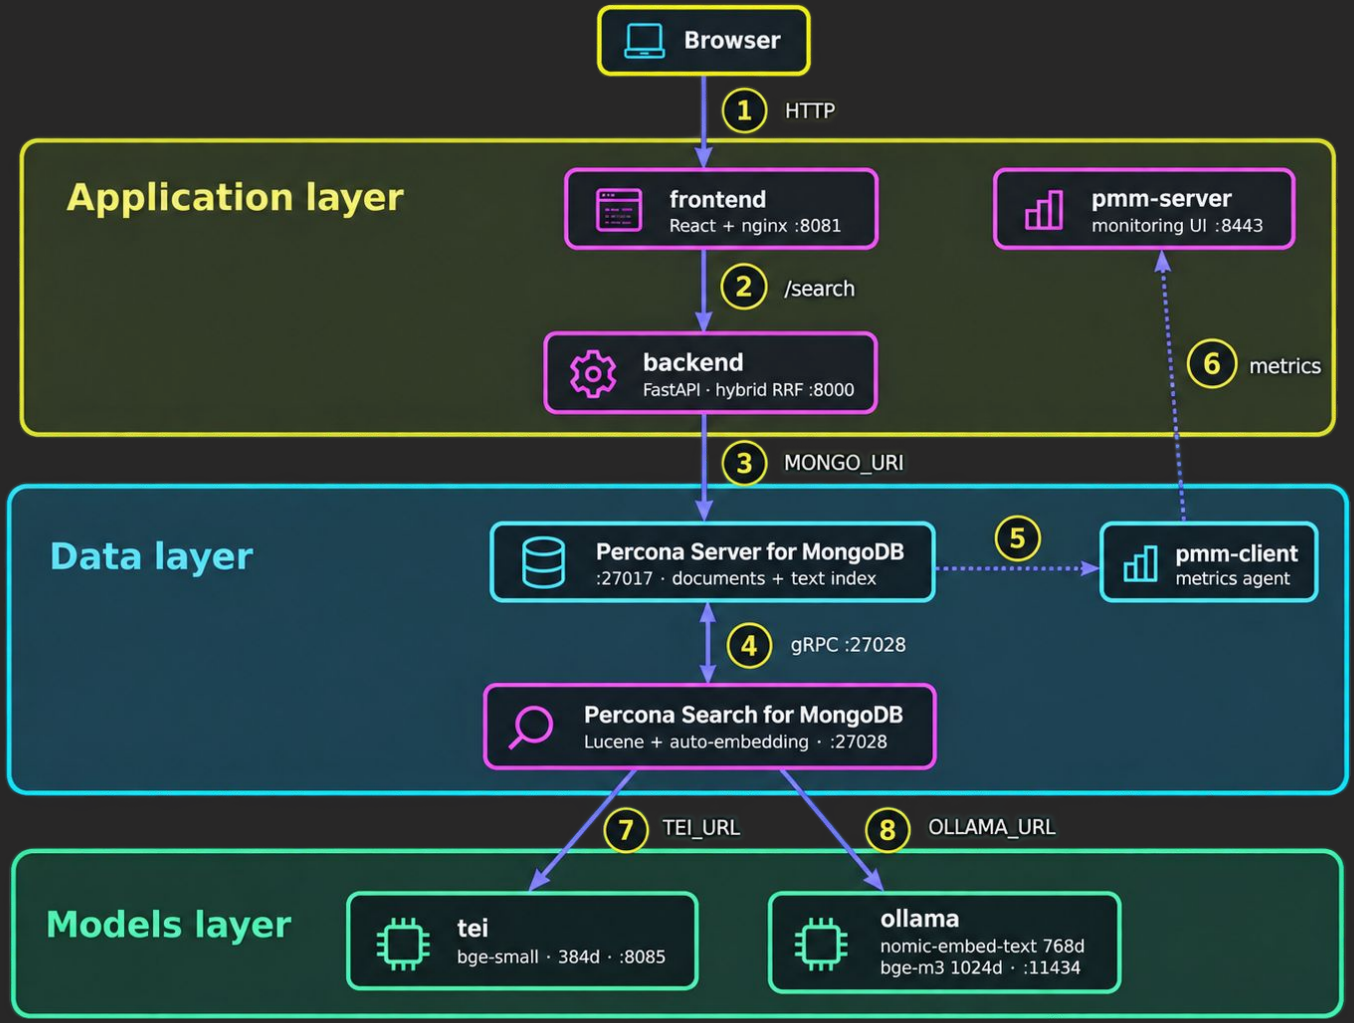
Live Demo:
Wyszukiwarka gier planszowych





PERCONA

Live Demo setup



Kiedy zostać przy SQL Server?

Uczciwie: nie każdy projekt potrzebuje nowej bazy danych

Zostań przy SQL Server, gdy:

- Twoje dane są relacyjne i już są w SQL Server, więc nie warto ich przenosić tylko dla wyszukiwania
- Skala jest umiarkowana, a wyszukiwanie wektorowe to dodatek, nie rdzeń produktu
- Potrzebujesz złączeń (JOIN) i transakcji na danych relacyjnych w jednym zapytaniu
- Zespół zna T-SQL i ekosystem Microsoft (Power BI, Fabric)

Rozważ MongoDB + Percona Search, gdy:

- Dane mają formę dokumentów, są zagnieżdżone lub mają zmienną strukturę (katalogi produktów, treści, zdarzenia)
- Wyszukiwanie jest rdzeniem aplikacji i musi skalować się niezależnie od bazy danych
- Czego jeszcze brakuje? Interfejsu SQL dla MongoDB, który pozwoli podłączyć narzędzia BI, np. Power BI, bezpośrednio do danych.

Kluczowe Wnioski

Przejmowanie kontroli nad swoimi danymi i architekturą sztucznej inteligencji



01

Kontekst jest krytyczny

Wyszukiwanie wektorowe stanowi istotny pomost między zasobami bazy danych a generatywną sztuczną inteligencją.

02

Odrzuć opłatę za wygodę

Nie powinieneś musieć rezygnować ze swobody architektonicznej, suwerenności danych czy korzystnej ekonomiki skalowania tylko po to, by zapewnić sobie szybkie wdrożenie.

03

Buduj na własnych zasadach

Percona Search for MongoDB zapewnia płynną automatyzację procesów, umożliwiając jednocześnie integrację z dowolnym modelem zgodnym z OpenAI.

PERCONA®

Dziękuję.
Czas na pytania.



Złapmy się na LinkedIn!

PERCONA

Bezczelna reklama od Jana

Zapraszamy na nowy event **PostgreSQL**!
PGConf.PL – Gdańsk – 24 listopada 2026



https://2026.pgconf.pl

PERCONA

Bezczelna reklama od Jana

Zapraszamy na nowy event **PostgreSQL**!
PGConf.PL – Gdańsk – 24 listopada 2026

- **Pierwszy** w historii coroczny event w Polsce!
- **Międzynarodowi** prelegenci!
- Wspaniałe miejsce do **networkingu** dla PostgreSQL Community!

PERCONA

Bezczelna reklama od Jana

Zapraszamy na nowy event **PostgreSQL**!
PGConf.PL – Gdańsk – 24 listopada 2026



Bruce Momjian
EDB



Gülçin Yıldırım Jelinek
ClickHouse



Vik Fearing
SQL StdDev



Alicja Kucharczyk
Guardioz.com



Aditya Surishetti
HexaCluster



Avinash Vallarapu
HexaCluster



Piotr Kolodziej
EDB



Alexander Kukushkin
Microsoft

Polina Bungina
Zalando SE